

Resumen metodológico de sesión II

De la distribución del corpus a la propuesta sin sesgos cognitivos (con DART)

Continuación del "Resumen metodológico de sesión" — cubre lo trabajado desde ese documento hasta ahora

Este documento consolida la segunda mitad de decisiones tomadas con el tutor: la distribución concreta de las 500 oraciones por medio/tema/género, la validación de la estrategia de segmentación automática, la priorización final de medios y temas, el marco DART como reemplazo del componente de diversidad, y el rediseño completo del flujo del sistema tras la decisión de retirar la simulación de históricos y la detección directa de sesgos cognitivos (confirmación/anclaje) del alcance del POC.

1. Distribución de las 500 oraciones

Se definió un grid de 5 medios $\times$ 5 temas = 25 celdas, con 20 oraciones por celda (500 en total), diferenciando cuántas de esas 20 provienen de noticia dura y cuántas de opinión/análisis según la fortaleza natural de cada medio.

Medio	Oraciones dura (de 20)	Oraciones opinión (de 20)	Total por medio
Infobae Colombia	14	6	100
El Tiempo	14	6	100
El Espectador	6	14	100
La Silla Vacía	8	12	100
Semana	10	10	100

Tabla 1. Distribución por medio. Total: 260 oraciones de noticia dura + 240 de opinión/análisis = 500.

Este grid, junto con el corpus real donde van las 500 oraciones con su anotación, quedó implementado en un archivo Excel de 4 hojas (Grid de recolección, Resumen automático por medio/tema, Leyenda, y Corpus - oraciones) — se adjunta de nuevo al final de este documento.

2. Segmentación lexicográfica de oraciones — comparación completa y recomendación final

Se identificó que dividir un artículo en oraciones por simple punto y espacio (". ") es poco confiable para el español periodístico: rompe abreviaturas, números con punto, y puede fragmentar el interior de una cita textual.

2.1 Diseño de la prueba

Se construyó un texto sintético de prueba (estilo prensa colombiana, sin contenido real de ningún medio) con 8 oraciones "gold" de referencia definidas a mano, diseñado para concentrar tres trampas: abreviaturas de título ("Dr.", "Sra.", "Ing."), una abreviatura de mes seguida de dos puntos ("14 de ago. de 2026:"), y comillas de cierre coincidiendo con un límite de oración. Se compararon 6 métodos: split ingenuo, spaCy (es_core_news_sm), y cuatro variantes de SaT (sat-1l-sm, sat-3l-sm, sat-6l-sm, sat-12l-sm).

2.2 Resultados

Método	Oraciones obtenidas	vs. gold (8)	Errores observados
Split ingenuo (". ")	12	+4	Rompe "Dr.", "EE. UU." ($\times 2$), "Sra.", "Ing."
spaCy es_core_news_sm	9	+1	Rompe "ago."; además desplaza la comilla de cierre en 2 citas (el límite queda bien, pero la puntuación migra a la oración siguiente)
SaT sat-1l-sm	10	+2	Rompe "Sra." y "ago." (comillas sí quedan intactas)
SaT sat-3l-sm	9	+1	Rompe solo "ago."
SaT sat-6l-sm	8	0	Ninguno — idéntico al gold
SaT sat-12l-sm	8	0	Ninguno — idéntico al gold

Tabla 1bis. Comparación de 6 métodos de segmentación sobre el texto de prueba ($n=1$ texto, 8 oraciones gold).

2.3 Hallazgos clave

- **El único punto donde fallan todos menos sat-6l-sm y sat-12l-sm:** "14 de ago. de 2026:" — abreviatura de mes seguida de dos puntos, que ni spaCy ni las versiones chicas de SaT resuelven.
- **El desplazamiento de comillas de spaCy no es cosmético:** si el segmentador separa el verbo de reporte ("afirmó:") de parte de la cita, el límite de oración deja de coincidir con el límite del enunciado atribuido a la fuente — afecta directamente la anotación de direccion/actor_objetivo.
- **sat-6l-sm y sat-12l-sm empatan en calidad (0 errores);** el desempate es de eficiencia, no de precisión.

2.4 Costo comparado: sat-6l-sm vs. sat-12l-sm

	sat-6l-sm	sat-12l-sm
Tamaño en disco	897 MB	1.1 GB (+~25%)
Carga inicial	~9s	~9.5s (prácticamente igual)
Inferencia (1 párrafo corto)	0.27s	0.52s (~2x, pero irrelevante en la práctica)
Calidad en la prueba	0 errores	0 errores (empate)

Tabla 1ter. Para un corpus POC de 100-500 oraciones, la diferencia de tiempo total entre ambos es de segundos, no de minutos.

2.5 Recomendación final

sat-12l-sm como segmentador primario. sat-6l-sm ya alcanza cero errores en la prueba, y en ese sentido sería suficiente — pero se opta por sat-12l-sm porque la diferencia de costo entre ambos es marginal para un corpus de este tamaño (unos 200 MB adicionales en disco, fracciones de segundo más de inferencia por párrafo) frente al margen adicional de robustez que da el modelo más grande ante casos que un texto de prueba de n=1 no necesariamente cubrió. Resuelve igual de bien los tres riesgos identificados (abreviaturas de título, abreviatura de mes, comillas de cita) y evita el problema de comillas desplazadas de spaCy, el más peligroso para la anotación de dirección/actor.

Estrategia final de pipeline:

- **Segmentador único:** sat-12l-sm, sin capa de verificación LLM por defecto — la evidencia de esta prueba no la justifica.
- **spaCy es_core_news_sm como fallback documentado** en el codebook, únicamente si el entorno final donde corran la anotación no tiene salida a Hugging Face — se verifica en el momento, sin asumir de antemano.
- **Validación pendiente antes de fijarlo como definitivo:** repetir la comparación sobre 20-30 párrafos reales de Infobae Colombia, no solo el texto sintético — un solo texto de prueba, aunque cubre las trampas clave, sigue siendo n=1.
- **Pregunta de codebook que sigue abierta:** cuando una cita larga contiene varias oraciones, ¿se anota cada una como registro separado, o la cita completa se trata como una sola unidad? sat-12l-sm (igual que sat-6l-sm) mantuvo la cita completa como una sola oración en la prueba porque así se construyó el texto — es una decisión editorial del equipo, no algo que emerja del segmentador.
- **Sobre el juez LLM:** es técnicamente factible y no comparte el riesgo de circularidad de la anotación de sesgo (validar que una oración esté bien formada estructuralmente no es juzgar contenido). Sí vale la pena mencionar en la metodología que, si el juez decide qué fragmentos se descartan, ejerce un efecto de selección

sobre qué termina anotándose. Con sat-12l-sm en cero errores, no parece necesario para la mayoría de los casos — se recomienda un filtro heurístico barato (fragmentos muy cortos, sin puntuación de cierre, comillas/paréntesis sin balancear) y reservar el juez LLM solo si, tras la validación en la muestra real de Infobae, sigue apareciendo un número significativo de fragmentos sospechosos.

3. Priorización final de medios (5 seleccionados)

Medio	Rol principal	Precaución
Infobae Colombia	Volumen de noticia dura — RSS + cuerpo completo embebido (content:encoded)	Ninguna detectada
El Tiempo	Noticia dura complementaria	Solo artículos gratuitos; aviso de copyright prohíbe uso del contenido para IA/ML sin autorización — pendiente de resolución legal con la universidad
El Espectador	Principalmente su sección Opinión	Evitar su noticia dura por riesgo de paywall en contenido "Premium"
La Silla Vacía	Análisis político — puente entre noticia dura y opinión	Verificar contenido exclusivo para "SuperAmigos" antes de asumir acceso 100% abierto
Semana	Volumen adicional de noticia dura/mixta	Sin RSS confirmado — usar scraping directo del listado de su sección

Tabla 2. Los 5 medios seleccionados con su rol y precauciones de acceso.

4. Tópicos / categorías polarizantes seleccionadas

Elegidos por generar cobertura desde ángulos políticos opuestos, condición necesaria para obtener variedad real de dirección/actor en el corpus:

- Transición de gobierno y relación con la oposición (posesión, Pacto Histórico, movilizaciones)
- Respuesta del Gobierno a la emergencia del terremoto
- Relación con Estados Unidos (aranceles, cooperación, visitas oficiales)
- Reformas sociales en disputa (pensional, tributaria, fallos de la Corte)
- Seguridad y orden público (cúpula militar, estatuto antiterrorista, grupos armados)

5. Características de noticias: dura vs. opinión/análisis

Hallazgo empírico consistente en todos los medios revisados con cuerpo completo: la noticia dura institucional es sistemáticamente pobre en sesgo léxico/discursivo propio del periodista, porque casi todo el lenguaje cargado que aparece está entre comillas y correctamente atribuido a una fuente identificada. El sesgo discursivo genuino apareció, con claridad, en columnas de opinión — y específicamente en columnas polémicas/personales, más que en piezas de análisis político respaldadas en cifras (que se comportan más como noticia dura).

Por eso la distribución de la sección 1 mezcla deliberadamente ambos géneros en proporción distinta según el medio (55%/45% aproximado en el agregado, ajustado por las fortalezas de cada uno), en vez de depender de un solo tipo de contenido.

6. DART como marco de recomendación con diversidad

6.1 Qué es y en qué se diferencia de un recomendador convencional

DART (Vrijenhoek et al.) propone cinco métricas —Calibración, Fragmentación, Representación, Activación y Voces alternativas— inspiradas en teoría democrática, pensadas para evaluar (y opcionalmente guiar) qué tan diverso es un conjunto de artículos recomendado.

La diferencia con un recomendador convencional (filtrado colaborativo, ranking por relevancia/popularidad, similitud de contenido) es de objetivo, no de técnica: un recomendador convencional optimiza para maximizar el compromiso predicho del usuario (clics, tiempo de lectura), lo cual tiende a reforzar sistemáticamente lo que el usuario ya prefiere — es, por diseño, el mecanismo que produce burbujas de filtro. Un selector consciente de DART aplica restricciones normativas explícitas (balance de posturas, inclusión de voces minoritarias, control de intensidad emocional) por encima o en lugar de la pura maximización de relevancia, aceptando cierto costo en engagement a cambio de pluralismo garantizado.

6.2 De dónde salen los datos — sin necesitar interacción real de usuarios

Solo Calibración exige un perfil histórico real de usuario (por eso se descartó al retirar la simulación de históricos). Representación, Activación y Voces alternativas se calculan directamente sobre las columnas ya anotadas (direccion, actor_objetivo, intensidad) de un conjunto de artículos candidato, sin necesitar que nadie haya leído ni reaccionado a nada. Fragmentación requiere comparar conjuntos servidos a 2-3 perfiles de consulta simples y estáticos (ej. "interesado en economía" vs. "interesado en seguridad"), mucho más liviano que una simulación histórica completa.

6.3 Ejemplo numérico — Representación

Pool de 20 artículos sobre "Reformas sociales en disputa": 12 perjudica al Gobierno (60%), 8 favorece (40%). Una línea base por popularidad podría entregar un top-5 100% "perjudica" (alta divergencia respecto al pool real → Representación baja). Un selector con restricción de balance entregaría, por ejemplo, 3 perjudica / 2 favorece (≈60/40, igual que el pool → Representación alta). Ambos números —el de la línea base y el del selector propuesto— son perfectamente reportables como resultado comparativo de la tesis.

6.4 Valor para la evaluación de la tesis

Al retirar la simulación de sesgos cognitivos, el sistema pierde su único punto de resultado cuantitativo comparativo. DART lo recupera sobre una base metodológica más sólida: comparar los scores DART de una línea base ingenua contra los del recomendador propuesto es un resultado real, medible con aritmética simple sobre datos ya anotados, sin necesidad de personas simuladas ni afirmaciones difíciles de sostener sobre cambio de creencias.

7. La nueva estrategia — flujo sin bloques de sesgos cognitivos

Se decidió, junto con el tutor, retirar del alcance del POC la simulación de históricos de usuario ("Nestor") y la detección directa de sesgos de confirmación/anclaje. La razón no es solo de tiempo: intentar demostrar con una simulación sintética que una explicación "cambia" el comportamiento futuro de un usuario simulado habría exigido programar esa respuesta de antemano — un diseño circular que no habría demostrado nada. El sistema queda así:




Figura 1. Flujo punta a punta v2 — anotación, selección de modelo, recomendación diversa (DART) y explicabilidad, sin simulación de históricos.

7.1 Por qué la explicabilidad sigue siendo el argumento central — y por qué se vuelve más defendible

El argumento de que la explicabilidad, más que la sola diversidad, tiene potencial de intervenir sobre el sesgo cognitivo del lector no dependía de Nestor en ningún momento. Se sostiene en dos pilares independientes de la simulación:

- **Respaldo bibliográfico:** Spinde et al. [8] ya muestran que la sola exposición a perspectivas diversas no cambia significativamente la percepción de sesgo — esto es una cita, no algo que el sistema deba demostrar por sí mismo.
- **La distinción visible/oculto:** el valor diferencial de la explicación está en revelar el mecanismo discursivo que el lector no detectaría por sí mismo. Esto conecta directamente con Bastian et al. [11] sobre transparencia algorítmica.

Lo oculto (camuflaje epistémico) se convierte así en el criterio que prioriza qué explica primero el Bloque 4 cuando una oración tiene más de un hallazgo — no una columna descriptiva más, sino la señal que ordena la narrativa de la explicación. Lo visible no pierde su lugar: sigue siendo necesario para la evaluación del detector (T2.3) y conserva cierto valor pedagógico secundario (nombrar con precisión lo que el lector ya intuía), pero como apoyo, no como protagonista del argumento de cambio de perspectiva.

Formulación defendible ante el jurado: se hipotetiza que la explicación de mecanismos discursivos ocultos tiene mayor potencial de generar reconsideración crítica que la de mecanismos léxicos visibles, ya intuitos por el lector. Esta hipótesis no se valida empíricamente dentro del alcance de este POC — queda como línea de trabajo futuro, potencialmente abordable en la prueba piloto condicional (T5.3), que gana relevancia al ser ahora el único punto donde el sistema podría obtener evidencia real (no simulada) sobre el efecto de la explicabilidad.

7.2 Cómo se conecta todo

Bloque 1 (anotación humana) alimenta directamente Bloque 2 (evaluación/selección de modelo de detección) y, vía direccion/actor_objetivo/intensidad, tanto al Bloque 3 (selector DART) como al Bloque 4 (explicabilidad, priorizando oculto). El resultado final combina un conjunto de artículos diverso (medido con DART) con una explicación que justifica esa diversidad citando el mecanismo discursivo concreto detectado en cada artículo — ningún componente depende de la simulación retirada.

8. Aclaración: las dos tablas de anotación no cambian

La Tabla 1 (esquema completo de 9 categorías, J1 léxico + J2 discursivo) y la Tabla 2 (esquema simplificado visible/oculto), tal como se definieron en el archivo "esquemas_ anotacion_sesgo_lexico_discursivo.xlsx", siguen exactamente vigentes. No se propuso ninguna categorización nueva — lo único nuevo es una regla de uso sobre una columna ya existente (percepcion=oculto como criterio de prioridad de explicación), no un cambio de estructura.

Columna	Justificación original	¿Sigue vigente sin Nestor?
es_sesgada, span	Evaluación T2.3 + evidencia para explicabilidad	Sí, sin cambios
percepcion (visible/oculto)	Distinción para priorizar qué explica el Bloque 4	Sí — gana protagonismo
direccion, actor_objetivo	Antes justificada en parte por Bloque 5 (Nestor)	Sigue igual de necesaria — ahora alimenta Representación, Activación y Voces alternativas (DART)
intensidad	Ponderar el índice de confirmación (Nestor)	Cambia de uso principal: prioridad de explicación + insumo de Activación (DART)

Tabla 3. Cada columna del esquema migra a justificarse por Bloque 3/4 en vez de por el Bloque 5 retirado — ninguna queda sin uso.

Recomendación final: mantener ambas tablas exactamente como están. La Tabla 1 sigue siendo el fundamento teórico citable en la metodología (Recasens 2013; Rodrigo-Ginés et al. 2024; Spinde et al. 2023); la Tabla 2 sigue siendo el esquema operativo con el que el profesional anota. El único documento que sí necesita una adición explícita es el manual de anotación (T1.2), incorporando la regla de prioridad oculto/visible en la sección del Bloque 4.

9. Comentarios finales y otros temas pendientes

- **Sobre la fuente de los datos de segmentación:** los resultados de la sección 2 se verificaron localizando la conversación original donde se ejecutaron (herramientas y comandos reales, no un resumen de segunda mano) — no se incorporaron sin esa verificación directa.
- **Tema legal pendiente:** sigue sin resolver la conversación con la universidad sobre el uso de El Tiempo (y medios con cláusulas similares) dado su aviso explícito de restricción de uso de contenido para IA/ML.
- **Título y objetivo general de la propuesta:** necesitan ajustarse para reflejar el alcance reducido — ya no se "detectan y mitigan sesgos cognitivos" de forma medible dentro del POC; se caracteriza sesgo mediático y se ofrece recomendación diversa + explicación, motivadas teóricamente por la literatura de sesgos cognitivos. Vale la pena plantear este ajuste de forma explícita con el profesor, no dejarlo implícito.

- **La prueba piloto (T5.3) gana peso:** al retirar Nestor, se convierte en el único punto del proyecto donde podría obtenerse evidencia real (no simulada) de que la explicabilidad mueve algo que la diversidad sola no mueve. Si el cronograma lo permite, priorizarla.
- **Pendiente técnico:** validar sat-12l-sm sobre una muestra real de 20-30 párrafos de Infobae Colombia (no solo el texto sintético) antes de fijarlo como segmentador definitivo del pipeline.
- **Pendiente de diseño:** definir la regla de codebook sobre citas largas con puntuación interna (¿unidad de anotación = oración gramatical, o cita completa hasta la comilla de cierre?).

Documento vivo — actualizar con las decisiones de sesiones posteriores.