

Sistema de monitorización y mitigación de sesgos cognitivos en el consumo de información digital proveniente de medios de comunicación colombianos

Sebastian Eduardo Fanchi y Andrés Darío Moreno Barbosa

Resumen—El consumo masivo de información digital ha consolidado los medios en línea como fuente primaria en la formación de opinión pública. La interacción entre sesgos mediáticos y sesgos cognitivos del lector —en particular el sesgo de confirmación y el de anclaje— amplifica la polarización y favorece la aparición de cámaras de eco. Pese a los avances internacionales en detección automática de sesgo mediante procesamiento de lenguaje natural (PLN), existe un vacío evidente en el ecosistema mediático hispanohablante y, específicamente, en el colombiano. Esta propuesta describe el diseño y prueba de concepto (POC) de un sistema que integra detección de sesgo léxico, recomendación con criterios de diversidad y un componente basado en modelos de lenguaje grande (LLM) para producir explicaciones transparentes al usuario. El sistema reutiliza componentes preexistentes y se evalúa mediante métricas técnicas; queda abierta la posibilidad de complementar la evaluación con una prueba piloto con usuarios al cierre del proyecto.

Index Terms—sesgo mediático, sesgo de confirmación, procesamiento de lenguaje natural, sistemas de recomendación, diversidad informativa, modelos de lenguaje grande, medios colombianos.

I. INTRODUCCIÓN

Los medios digitales se han convertido en el canal informativo predominante para amplios sectores de la población colombiana, desplazando progresivamente a los formatos impresos y televisivos tradicionales [1]. Esta transición ha intensificado los efectos de los sesgos mediáticos: los algoritmos de personalización de contenidos pueden reforzar selectivamente las creencias del usuario y generar lo que la literatura denomina burbujas de filtro y cámaras de eco. Cuando ese efecto algorítmico se combina con el sesgo de confirmación —la tendencia a buscar y valorar información que confirme las creencias ya sostenidas— y con el sesgo de anclaje —la influencia desproporcionada del primer dato recibido sobre juicios posteriores—, el resultado es una exposición sistemáticamente unidireccional que erosiona la deliberación pública y la formación de juicios equilibrados.

El problema adquiere especial relevancia en Colombia, donde el ecosistema mediático digital presenta inclinaciones ideológicas marcadas y los lectores rara vez disponen de herramientas explícitas para identificar y contrarrestar el sesgo en el contenido que consumen. A este escenario se suma la

ausencia casi total de recursos computacionales orientados al español del país: la mayoría de corpus de sesgo, clasificadores y pipelines de PLN disponibles en la literatura han sido construidos sobre el inglés y el ecosistema mediático estadounidense [2], [3]. Esta brecha geográfica y lingüística representa, al mismo tiempo, una limitación metodológica y una oportunidad de investigación concreta.

Esta propuesta busca cerrar parcialmente esa brecha mediante una POC que integre componentes ya disponibles —modelos de lenguaje preentrenados, embeddings semánticos, LLM generativos— en un sistema funcional adaptado al español de Colombia. El énfasis no se sitúa en el entrenamiento de nuevos modelos sino en la articulación de piezas existentes, el diseño de criterios de diversidad alineados con marcos normativos, y la dimensión psicológica y explicativa de las recomendaciones.

II. ESTADO DEL ARTE

A. Sesgo mediático: definición y formas de manifestación

El sesgo mediático ha sido definido como la cobertura inclinada o sesgo interno reflejado en los artículos de noticias, sea por intención deliberada del periodista o por procesos involuntarios en la cadena editorial [3]. Hamborg sistematiza sus tipos —de selección, de presentación, de encuadre y por elección léxica— y discute las técnicas de PLN aplicables a cada uno de ellos. Entre estas formas, el sesgo por elección léxica resulta especialmente relevante para esta propuesta: ante un mismo hecho, el periodista puede seleccionar términos que inducen connotaciones emocionales o valorativas muy distintas en el lector. La relevancia del fenómeno se amplifica porque, al combinarse con la confianza diferencial que los lectores depositan en los medios, modifica de forma significativa la valoración de las fuentes informativas y la credibilidad que les atribuyen [2].

B. Detección automática de sesgo mediante PLN

Recasens *et al.* [4] establecieron las primeras aproximaciones lingüísticas sistemáticas a la detección de lenguaje sesgado, identificando categorías como verbos factivos, verbos asertivos, palabras subjetivas y *hedges*. Sobre esa base, Spinde *et al.* [1] construyeron el referente metodológico contemporáneo: un corpus anotado con etiquetado a nivel de palabra y oración que incorpora información sociodemográfica e ideológica de los anotadores, reconociendo que la percepción del sesgo no es uniforme entre lectores con distintos perfiles ideológicos. Sus experimentos evidencian la dificultad intrínseca de la

tarea, tanto por la subjetividad del fenómeno como por la escasez de recursos anotados de calidad. Más recientemente, Raza *et al.* [5] han argumentado que los modelos basados en transformers capturan formas más sutiles de sesgo que los enfoques léxicos tradicionales, motivando la estrategia de reutilización de modelos preentrenados que adopta esta propuesta.

C. Percepción del sesgo y medición empírica

La detección automática enfrenta un desafío de fondo: la percepción del sesgo es subjetiva y depende del perfil ideológico, los hábitos de consumo y las creencias previas del lector. Hamborg *et al.* [6] estudiaron en particular el sesgo focalizado en personas —la cobertura diferenciada según el personaje protagonista de la noticia— y su impacto en el consumo cotidiano de información. De manera complementaria, Spinde *et al.* [7] construyeron un instrumento de medición validado en un estudio empírico de amplio alcance que examina cómo los lectores perciben y valoran el sesgo en los artículos. Su análisis identifica varios factores latentes en la percepción del sesgo; entre ellos, la *orientación política* percibida muestra las correlaciones más fuertes con clasificaciones externas de referencia. Este instrumento constituye la base empírica para evaluar, en una eventual prueba piloto, la efectividad del sistema de mitigación propuesto.

D. Visualización y comunicación del sesgo

Spinde *et al.* [8] compararon estrategias agnósticas y conscientes del sesgo en un estudio experimental con usuarios reales. Sus resultados muestran que las anotaciones basadas en análisis de contenido manual comunican los sesgos más eficazmente que las visualizaciones de encuadre. Sin embargo, el hallazgo más relevante para esta propuesta es que la mera exposición a perspectivas opuestas no altera de forma significativa la percepción de sesgo del usuario. Este resultado, coherente con investigaciones previas sobre resistencia al cambio de actitudes, sugiere que las estrategias de mitigación deben acompañarse de explicaciones que motiven activamente al usuario a interesarse en perspectivas distintas.

E. Recomendación de noticias con diversidad

Vrijenhoek *et al.* [9] proponen el marco *Recommenders with a Mission*, en el cual los sistemas de recomendación noticiosa se evalúan no solo por su precisión predictiva sino también por la diversidad, inclusión y representación de voces que producen. El trabajo introduce métricas alineadas con teorías normativas de democracia —calibración, fragmentación, representación, activación— que resultan directamente aplicables a los objetivos de mitigación de esta propuesta. De manera complementaria, Alam *et al.* [10] estudian el sesgo introducido por los propios sistemas de recomendación mediante análisis de sentimiento y detección de postura, evidenciando que la arquitectura algorítmica puede amplificar o atenuar el sesgo presente en el corpus subyacente. Estos dos trabajos sitúan el problema del sesgo no únicamente en el contenido producido por los medios, sino también en los mecanismos de selección y distribución del mismo.

F. Transparencia y explicación a usuarios

Bastian *et al.* [11] analizan, desde una perspectiva multipaís, cómo los sistemas de personalización noticiosa explican sus decisiones a los usuarios y concluyen que la transparencia algorítmica es, en general, insuficiente y heterogénea entre países y tipos de medios. Los usuarios rara vez reciben información clara sobre los criterios que determinan el contenido que les es mostrado. La emergencia reciente de LLM abre la posibilidad de generar justificaciones en lenguaje natural, contextualizadas y adaptadas al usuario, lo que combina los hallazgos de diversidad con los de transparencia y constituye uno de los componentes diferenciadores de esta propuesta.

G. Brechas identificadas

El análisis bibliométrico realizado en la fase anterior de esta investigación —sobre 15.019 documentos consolidados en Scopus y procesados con VOSviewer mediante grafos de co-autoría y co-ocurrencia de palabras clave— evidenció tres brechas principales: (i) ausencia casi total de literatura aplicada al ecosistema mediático hispanohablante y, concretamente, al colombiano; (ii) integración aún incipiente entre detección de sesgo, recomendación con diversidad y modelos generativos para explicación; y (iii) limitada validación experimental que conecte la calidad técnica del sistema con cambios efectivos en la percepción informativa del lector. La ausencia de autores latinoamericanos en el grafo de co-autoría corrobora además el vacío geográfico que esta investigación podría contribuir a llenar. Estas tres brechas, sumadas a la dependencia metodológica de los corpus en inglés, configuran el espacio de contribución original de esta propuesta.

III. PREGUNTA DE INVESTIGACIÓN Y OBJETIVOS

A. Pregunta de investigación

A partir del estado del arte y las brechas identificadas, se formula la siguiente pregunta motivadora:

¿En qué medida la exposición unidireccional a contenido sesgado en medios digitales colombianos refuerza el sesgo de confirmación y el de anclaje en lectores hispanohablantes, y bajo qué condiciones es posible atenuar dicho efecto cuando el ecosistema informativo expone al lector a perspectivas diversas, contextualizadas y justificadas de forma transparente?

Esta pregunta pone el énfasis en el problema —la amplificación de sesgos cognitivos por el consumo unidireccional— y no en la solución técnica particular, dejando abierto el espacio metodológico para las decisiones de diseño que se detallan en la Sección IV.

B. Objetivo general

Diseñar, implementar y evaluar, a nivel de prueba de concepto, un sistema para la monitorización y mitigación de sesgos cognitivos en el consumo de información digital proveniente de medios de comunicación colombianos, mediante la integración de componentes preexistentes de PLN, recomendación con criterios de diversidad y LLM para la generación de explicaciones transparentes al usuario.

C. Objetivos específicos

- OE1.** Establecer una base de datos anotada de noticias del ecosistema mediático colombiano con marcadores de sesgo a nivel de palabra y oración. La estrategia de obtención se definirá tras un estudio de viabilidad y podrá consistir en adaptación de corpus existentes, anotación asistida por LLM, generación sintética con sesgo controlado, o una combinación de las anteriores.
- OE2.** Integrar y evaluar modelos preentrenados para la detección de sesgo léxico adaptados al español, comparando su desempeño en el contexto colombiano sin entrenamiento ni ajuste fino, en línea con el enfoque de reutilización de transformers reportado por Raza *et al.* [5].
- OE3.** Diseñar un módulo de recomendación de contenido que promueva la diversidad de perspectivas y la mitigación del sesgo de confirmación, fundamentado en el marco normativo de Vrijenhoek *et al.* [9], con énfasis en el diseño algorítmico y los criterios de diversidad.
- OE4.** Implementar un componente basado en LLM que justifique cada recomendación en lenguaje natural, con explicaciones sobre el sesgo detectado, el motivo de la sugerencia y la diversidad ofrecida, atendiendo el principio de transparencia algorítmica discutido por Bastian *et al.* [11].
- OE5.** Evaluar el sistema integrado mediante métricas técnicas de calidad de recomendación, rendimiento, fidelidad de explicaciones y trazabilidad, con la posibilidad de complementar con una prueba piloto con usuarios condicionada a la disponibilidad de tiempo y recursos al cierre del proyecto.

IV. METODOLOGÍA

La aproximación metodológica se estructura en cinco bloques secuenciales, cada uno asociado a un objetivo específico y con entregables verificables. El proyecto adopta deliberadamente un alcance de POC: no se contempla entrenamiento ni ajuste fino de modelos desde cero, y la validación sigue el ciclo iterativo *datos* → *integración* → *sistema* → *evaluación*.

A. Bloque 1 — Base de datos anotada (OE1)

- T1.1** Realizar un estudio breve de viabilidad que compare tres estrategias de obtención de datos: adaptación de corpus existentes mediante traducción asistida o transferencia de dominio, anotación asistida por LLM sobre noticias colombianas seleccionadas, y generación sintética con sesgo controlado. La elección dependerá de la complejidad técnica y los tiempos observados en cada alternativa.
- T1.2** Diseñar el codebook de anotación con definiciones operativas, ejemplos representativos y reglas de desambiguación aplicables con independencia de la estrategia escogida.
- T1.3** Construir la base de datos con la estrategia seleccionada (objetivo indicativo: 100–300 oraciones con etiquetas a nivel de palabra y oración).
- T1.4** Verificar cualitativamente una muestra representativa de las anotaciones, contrastando los resultados con el juicio del investigador y documentando los casos límite.

B. Bloque 2 — Módulo de detección de sesgo (OE2)

- T2.1** Inventariar modelos preentrenados para detección de sesgo, sentimiento y postura, evaluando idioma soportado, licencia, costo de inferencia y métricas reportadas en la literatura.
- T2.2** Implementar la pipeline de inferencia reutilizando al menos un modelo seleccionado; incorporar estrategias de prompting (zero-shot, few-shot) en LLM cuando no existan modelos especializados en español para la tarea.
- T2.3** Reportar el desempeño del módulo (precisión, recall y F1 aproximados sobre la base del Bloque 1) y analizar cualitativamente los errores para discutir la transferibilidad al contexto mediático colombiano.

C. Bloque 3 — Motor de recomendación con diversidad (OE3)

- T3.1** Construir un índice vectorial de artículos representativos del espectro ideológico colombiano, empleando modelos de embeddings disponibles y tecnologías de código abierto apropiadas para un POC de bajo costo de inferencia.
- T3.2** Implementar un algoritmo de re-ranking que optimice conjuntamente relevancia y diversidad, parametrizado por un subconjunto de las métricas de Vrijenhoek *et al.* [9] seleccionado según su viabilidad en el contexto del POC.
- T3.3** Comparar el módulo frente a un baseline basado únicamente en similitud semántica y documentar las decisiones de diseño mediante un registro de arquitectura.

D. Bloque 4 — Componente generativo de explicación (OE4)

- T4.1** Diseñar y prototipar iterativamente prompts estructurados que generen explicaciones sobre: (a) el sesgo detectado en el artículo de referencia, (b) la justificación de la recomendación y (c) la diversidad de perspectivas ofrecida.
- T4.2** Integrar el LLM con los módulos de detección y recomendación, incorporando guardrails para restringir alucinaciones y una capa de grounding que verifique la consistencia de las explicaciones con la salida del Bloque 2.
- T4.3** Implementar un módulo de evaluación automática tipo *LLM-as-a-Judge* para estimar la fidelidad y completitud de las explicaciones generadas.

E. Bloque 5 — Evaluación del sistema integrado (OE5)

- T5.1** Definir el conjunto de métricas técnicas e instrumentar el sistema para registrarlas mediante logs estructurados, trazas de inferencia y paneles de observabilidad.
- T5.2** Ejecutar la batería de evaluación técnica y producir el reporte de resultados: calidad de recomendaciones (relevancia, diversidad, cobertura), métricas de rendimiento (latencia, costo de inferencia), fidelidad de explicaciones según el juez automático del Bloque 4, y trazabilidad del flujo completo.
- T5.3** (Condicional) Si el cronograma lo permite, diseñar y ejecutar una prueba piloto con un grupo reducido de 20–30 usuarios voluntarios, empleando una adaptación al español del instrumento de Spinde *et al.* [7].

T5.4 Consolidar, revisar y entregar el documento final del trabajo de grado —cuya redacción se desarrolla de forma transversal a lo largo de todo el proyecto— y preparar un artículo científico para sometimiento a una publicación del área.

V. CRONOGRAMA

El proyecto se ejecuta durante un semestre de 17 semanas. Cabe señalar que, de acuerdo con las últimas directrices de la Pontificia Universidad Javeriana, el semestre vigente fue reducido de 18 a 17 semanas, por lo que el cronograma se ajusta a esa extensión. La Tabla I presenta la asignación temporal de cada tarea.

Es importante precisar que la redacción del documento de grado es una actividad transversal: cada bloque produce secciones que se integran progresivamente al documento final desde el inicio del proyecto. T5.4 representa la etapa de consolidación, revisión y entrega, no el punto de partida de la escritura. Por su parte, la preparación de un artículo científico para sometimiento está contemplada como entregable del proyecto desde la propuesta inicial (entregable E5.4 de la Tarea 4 del Seminario de Investigación). Las tareas T5.1 y T5.3 se inician en paralelo con el Bloque 4 para optimizar el tiempo disponible.

Cuadro I
CRONOGRAMA DE EJECUCIÓN (SEMESTRE DE 17 SEMANAS)

Bloque	Tarea	Semanas
B1	T1.1 Estudio de viabilidad de datos	1–2
	T1.2 Codebook de anotación	2–3
	T1.3 Construcción de la base de datos	3–5
	T1.4 Verificación cualitativa	5
B2	T2.1 Inventario de modelos preentrenados	5–6
	T2.2 Pipeline de inferencia	6–8
	T2.3 Análisis cualitativo de errores	8
B3	T3.1 Índice vectorial de artículos	8–10
	T3.2 Algoritmo de re-ranking	10–12
	T3.3 Evaluación comparativa	12
B4	T4.1 Diseño iterativo de prompts	12–13
	T4.2 Integración LLM + guardrails	13–14
	T4.3 Módulo LLM-as-a-Judge	14–15
B5	T5.1 Métricas e instrumentación	14–15
	T5.2 Evaluación técnica	15–16
	T5.3 Prueba piloto (condicional)	16
	T5.4 Consolidación y entrega del documento	16–17
Transv.	Redacción continua del documento de grado	1–17

VI. ALCANCE Y LIMITACIONES

Este trabajo se concibe como una POC y asume conscientemente varias restricciones. Primero, no se contempla el entrenamiento ni el ajuste fino de modelos: la contribución se centra en la integración de componentes existentes, en el diseño de los criterios de diversidad y en la dimensión psicológica y explicativa de las recomendaciones. Segundo, el tamaño de la base de datos del Bloque 1 dependerá del estudio de viabilidad y podría limitarse a un conjunto reducido de oraciones obtenido

mediante adaptación de corpus existentes, anotación asistida o generación sintética. Tercero, las explicaciones generadas por el componente LLM pueden incorporar sesgos del modelo subyacente, lo que motiva el uso explícito de guardrails y evaluación automática descritos en el Bloque 4. Cuarto, la evaluación con usuarios reales se mantiene como posibilidad condicional; de realizarse, se aplicarán los protocolos institucionales de consentimiento informado vigentes en la Pontificia Universidad Javeriana. La generalización de los hallazgos a otros contextos hispanohablantes queda, finalmente, como línea de trabajo futuro.

REFERENCIAS

- [1] T. Spinde, L. Rudnitskaia, J. Mitrović, F. Hamborg, M. Granitzer, B. Gipp, y K. Donnay, “Automated identification of bias inducing words in news articles using linguistic and context-oriented features,” *Information Processing & Management*, vol. 58, no. 3, p. 102505, 2021. doi: 10.1016/j.ipm.2021.102505.
- [2] A. Ardèvol-Abreu y H. Gil de Zúñiga, “Effects of editorial media bias perception and media trust on the use of traditional, citizen, and social media news,” *Journalism & Mass Communication Quarterly*, vol. 94, no. 3, pp. 703–724, 2017.
- [3] F. Hamborg, *Revealing Media Bias in News Articles: NLP Techniques for Automated Frame Analysis*. Cham, Suiza: Springer, 2023. ISBN: 978-3-031-17693-7.
- [4] M. Recasens, C. Danescu-Niculescu-Mizil, y D. Jurafsky, “Linguistic models for analyzing and detecting biased language,” en *Proc. 51st Annual Meeting of the ACL*, Sofía, Bulgaria, ago. 2013, pp. 1650–1659.
- [5] S. Raza, O. Bamgbose, V. Chatrath, y S. Ghuge, “Unlocking bias detection: Leveraging transformer-based models for content analysis,” *IEEE Trans. Computational Social Systems*, 2024.
- [6] F. Hamborg, T. Spinde, K. Heinser, y K. Donnay, “How to effectively identify and communicate person-targeting media bias in daily news consumption?” en *Proc. 2021 ACM SIGIR CHIIR*, 2021.
- [7] T. Spinde, C. Kreuter, W. Gaissmaier, F. Hamborg, B. Gipp, y H. Giese, “Do you think it’s biased? How to ask for the perception of media bias,” en *2021 ACM/IEEE JCDL*, 2021, pp. 61–69. doi: 10.1109/JCDL52503.2021.00018.
- [8] T. Spinde, F. Hamborg, K. Donnay, A. Becerra, y B. Gipp, “Enabling news consumers to view and understand biased news coverage: A study on the perception and visualization of media bias,” en *Proc. ACM/IEEE JCDL 2020*, Virtual Event, China, ago. 2020, pp. 389–392. doi: 10.1145/3383583.3398619.
- [9] S. Vrijenhoek, M. Kaya, N. Metoui, J. Möller, D. Odiijk, y N. Helberger, “Recommenders with a mission: Assessing diversity in news recommendations,” en *Proc. CHIIR ’21*, 2021, pp. 173–183. doi: 10.1145/3406522.3446019.
- [10] M. Alam, A. Iana, A. Grote, K. Ludwig, P. Müller, y H. Paulheim, “Towards analyzing the bias of news recommender systems using sentiment and stance detection,” en *Companion Proc. Web Conference 2022*, 2022, pp. 448–457.
- [11] M. Bastian, M. Makhortykh, J. Harambam, y M. van Drunen, “Explanations of news personalisation across countries and media types,” *Internet Policy Review*, vol. 9, no. 4, 2020.